Hacia los modelos (estadísticos) de medición:

Teoria clásica del test (TCT)

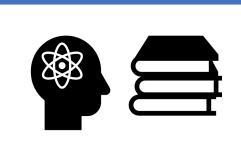




Fenómenos (ante los ojos)

¥

Objetos científicos

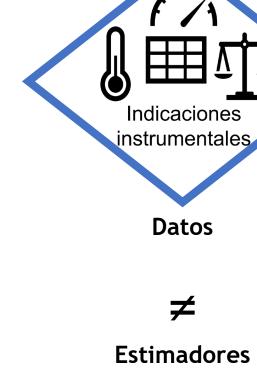


Resultados de Medición

Fenómenos (ante los ojos)



Observación (codificada)



Estimadores

¥

Indicaciones

Datos



Puntajes (scores)

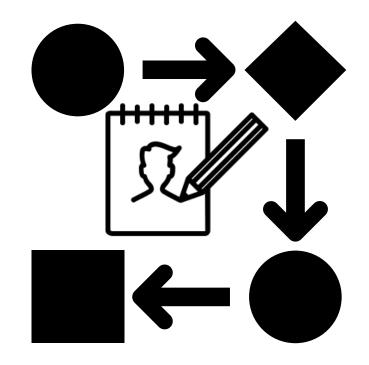




Puntajes



Objetos científicos



Modelo de medición

- Una representación abstracta y local construida a partir de supuestos simplificadores
- Hipótesis teóricas sobre las relaciones que guardan los instrumentos con aquello que se quiere medir y con el ambiente ([DAG] sobre cómo fueron producidos los datos)
- Modelo teórico y estadístico del proceso de medición mismo
- Permite la rastreabilidad/trazabilidad de la generación de los resultados de la medición (a lo largo de cada eslabón de la cadena) en su relación con aquello que se quiere medir
- Establece relaciones cuantitativas entre aquello que se quiere medir y el resultado de su medición
- Generativos: genera instancias de datos (inputoutput de acuerdo con el proceso de medición idealizado)



Confiabilidad y validez Sólo bajo el modelo de medición

- 1. Mental health screening of preschool children: Validity and reliability of ABLE. American Journal of Orthopsychiatry, 77(3), 402-418, 402.
 - ABLE (Attention, Behavior, Language, and Emotions), a new screening tool, was used to estimate the prevalence and the severity of concerns parents and teachers have about children's school adjustment and evaluate their need for services. Data obtained from parents and teachers of children randomly selected from public Pre-K classrooms in 6 states (N = 415) and from a mental health screening of rural and urban children (N = 5,577) support the validity and reliability of ABLE. Barbarin, O. A. (2007).
- 2. Hides, L., Dawe, S., Young, R. McD., & Kavanagh, D. J. (2006). The reliability and validity of the Severity of Dependence Scale for detecting cannabis dependence in psychosis. *Addiction*, 102, 35-40.
 - The SDS [Severity of Dependence Scale] is a brief, valid and reliable screen for cannabis dependence among people with psychosis.



Trivializar la medición

Afirmaciones acerca de que

- Aquello que se quiere medir es observable
- La medición es un tipo de observación en sí misma que no necesita de modelaje

Reducen el significado de aquello que se quiere medir a un conjunto de datos y las operaciones involucradas



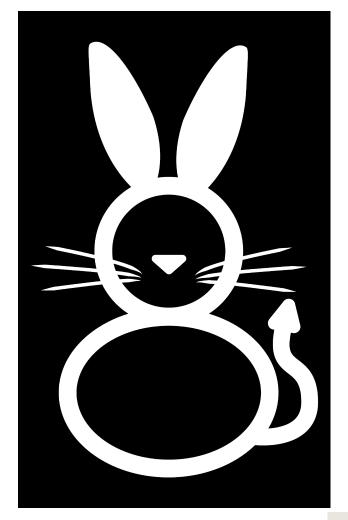


- Ausencia de error de medición
- Interpretabilidad representacional automática



Trivializar la medición

- Compromete la generalización científica (interpretaciones comunes de los resultados, independientemente de los procedimientos específicos)
- Comparaciones cuantitativas, geográficas y en el tiempo, pueden confundirse con aquello que queremos medir
- Diferencias espurias, enmascarar diferencias genuinas, conclusiones incorrectas





TCT: ¿Cómo llegamos aquí?

Progresión no lineal de la historia, acuerdos y desacuerdos de lo que significa medir en ciencias

- Siglo XX: Teoría representacional
- Siglo XXI: Medición basada en modelos

Mientras tanto...



Orígenes de la teoría clásica como modelo estadístico de medición

La historia de esta teoría comienza a la vuelta del siglo XX (1904)

- Spearman, C. (1904). "General Intelligence," objectively determined and measured. *The American Journal of Psychology*, 15(2), 201-292.
- Spearman, C. (1904). The proof and measurement of association between two things. *American journal of Psychology*, 15(1), 72-101.




Charles Edward Spearman 1863-1945

15,000 citas en GS!



Origen la teoría clásica del test y SEM como modelos estadísticos de medición





Tres ideas



- Atenuación de correlación por error
- El error como variable aletoria
- Distinción entre variables observables (con error) y variable latent

Pilares de Teoría clásica del test y eventualmente de ecuaciones estructurales

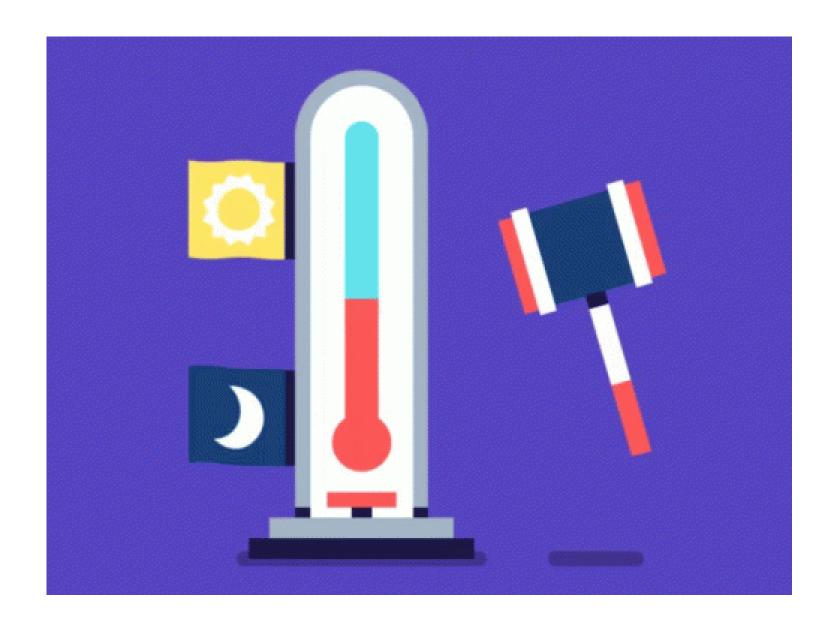
Orígenes de modelos reflexivos / generativos de medición



El día de hoy: Teoría clásica del test

- Una representación abstracta y local construida a partir de supuestos simplificadores
- Hipótesis teóricas sobre las relaciones que guardan los instrumentos con aquello que se quiere medir y con el ambiente ([DAG] sobre cómo fueron producidos los datos) Modelo teórico y estadístico del proceso de medición mismo
- Permite la rastreabilidad/trazabilidad de la generación de los resultados de la medición (a lo largo de cada eslabón de la cadena) en su relación con aquello que se quiere medir
- Establece relaciones **cuantitativas** entre aquello que se quiere medir y el resultado de su medición
- Generativos: genera instancias de datos (input-output de acuerdo con el proceso de medición idealizado)



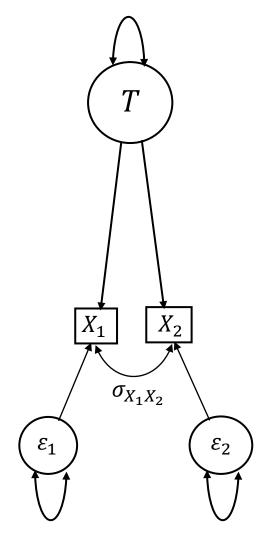


La idea de rastrear la señal (hacer observable lo inobservable) está en el centro de la medición científica

Estimar magnitudes modelando las consecuencias de que cierto fenómeno varía

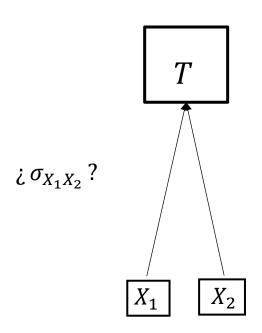


TCT: Modelos reflexivos



¿Son las indicaciones las que varían según varía el fenómeno?

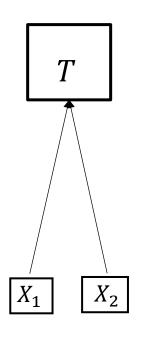
Modelos formativos

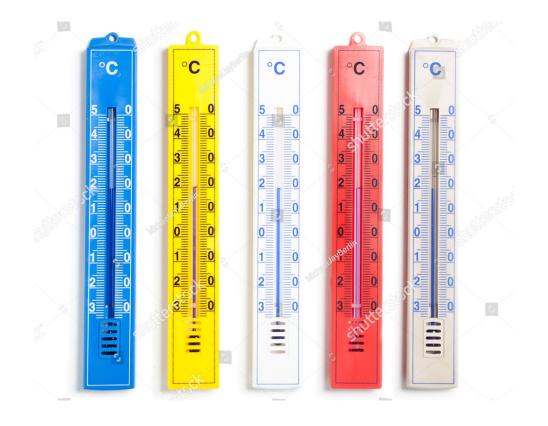


¿Son las indicaciones las que definen al fenómeno?



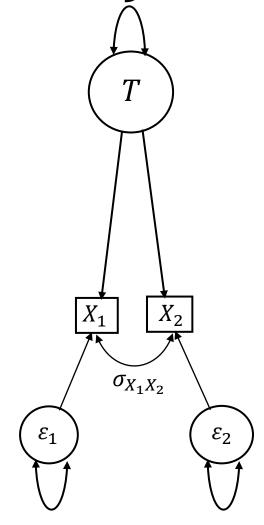
Las indicaciones de múltiples termómetros definen la temperatura

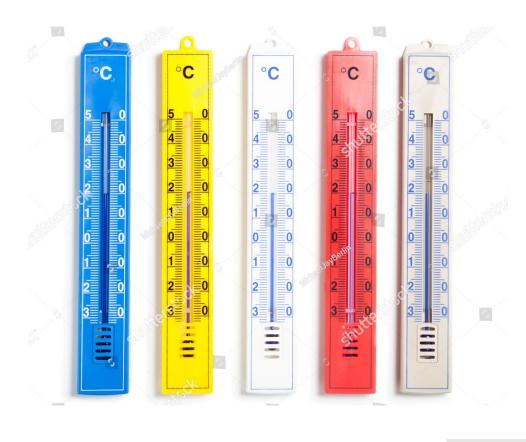






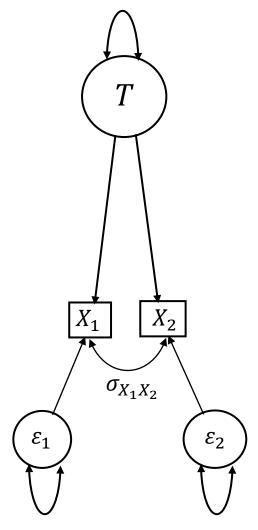
Las indicaciones de múltiples termómetros son reflejo de cambios en la temperatura



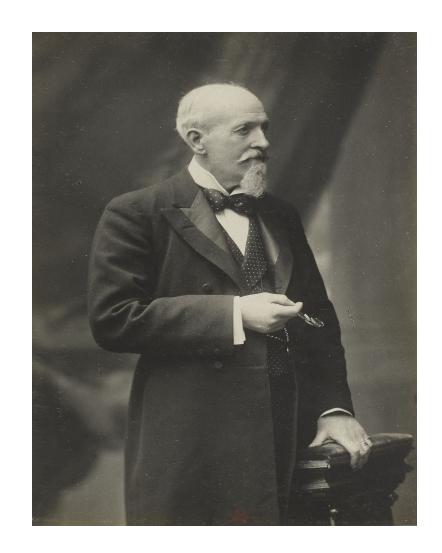




TCT: Modelos reflexivos



¿Son las indicaciones las que varían según varía el fenómeno?



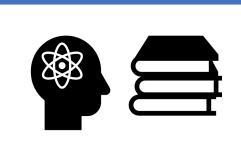




Fenómenos (ante los ojos)

¥

Objetos científicos

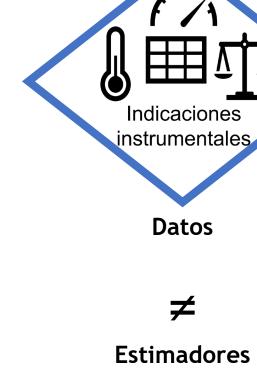


Resultados de Medición

Fenómenos (ante los ojos)



Observación (codificada)



Estimadores

¥

Indicaciones

Datos



Puntajes (scores)



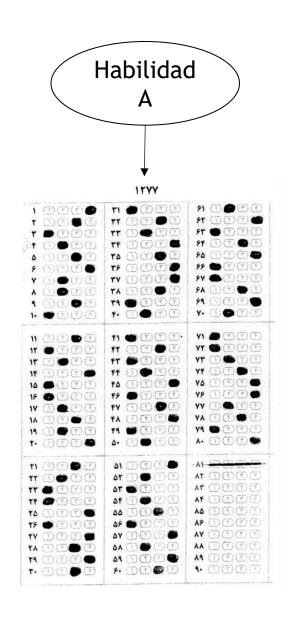


Puntajes



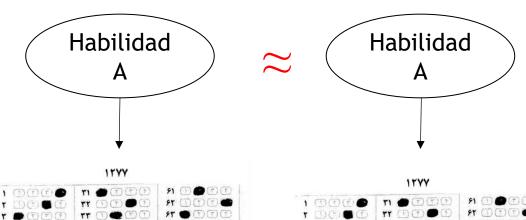
Objetos científicos



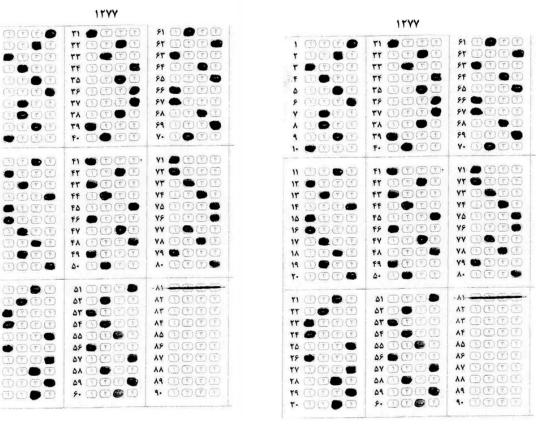


Supuesto del modelo de Spearman: Si las respuestas rastrean/son causa de la misma "señal", deberían estar correlacionadas "intra-sujetos"









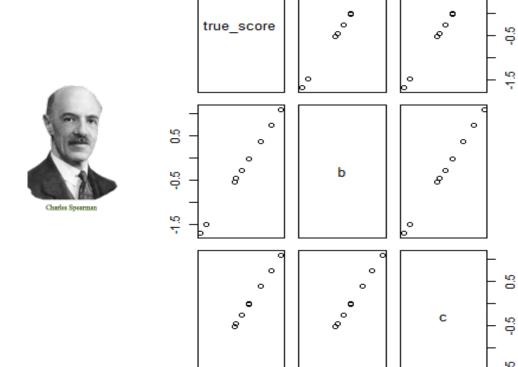
Dos:

tests/preguntas/ tiempos

Si las respuestas rastrean/son causa de la misma "señal", deberían estar correlacionadas "intra-sujetos" pero también "inter-sujetos"



Introducción de la idea de variable latente (modelo reflexivo)



0.0 1.0

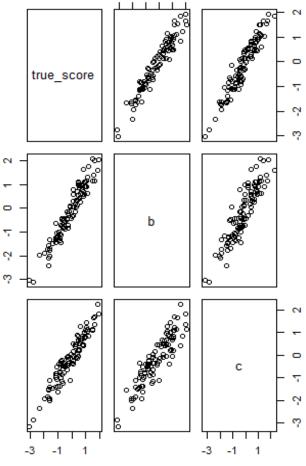
b = T + e ... e = 0

0.0 1.0

-1.5 0.0 1.0

Suponemos que b y c son

consecuencias/reflejo/pr oducto/resultado de T



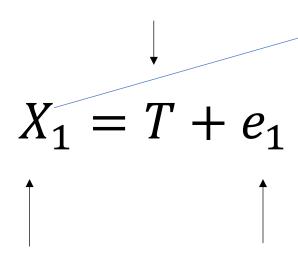
-3 -1 1

b = T + e ... e > 0



Teoría clásica del test

Score verdadero: La inferencia del resultado de medición según cierta indicación instrumental



Inferencia score observado:

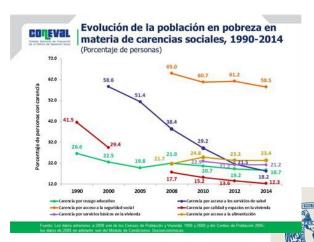
Indicaciones

Indicadores

Lo que no te interesa y distorsiona lo que concluyes a partir de X









Teoría clásica del test

Score verdadero: Lo que quisieras medir/representar bajo un modelo/Resultado

$$X_1 = T + e_1$$





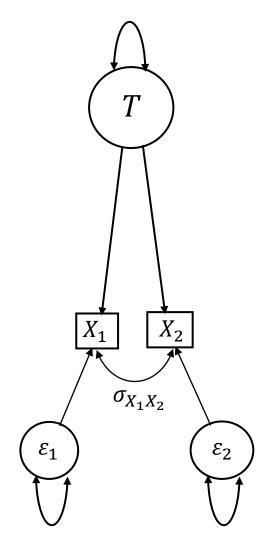
Score observado:

Indicaciones

Indicadores

Lo que no te interesa y distorsiona lo que

concluyes a partir de





¿De qué forma añade esa variabilidad?

Segun la TCT se traduce en lo siguiente

Para la primera medida tenemos poco error:

 $e_1 \sim N(0,.1)$

Suponen error aleatorio

$$X_1 = T + e_1$$

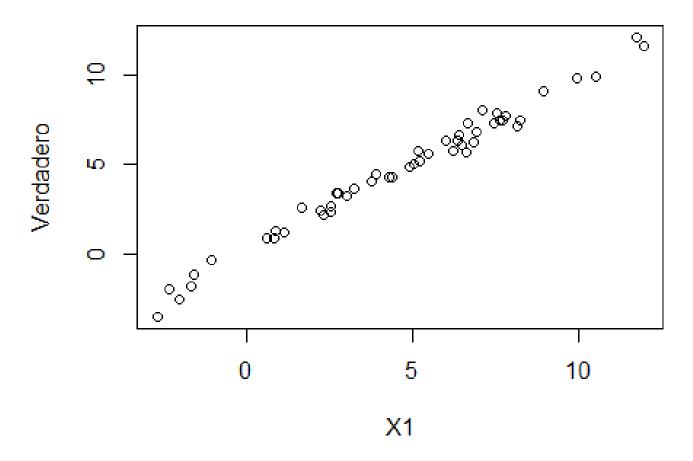
Las respuestas de la estudiante "A" tienen poca variabilidad.

Es muy consistente

Si esto se extiende al resto del grupo, estamos haciendo una buena medición



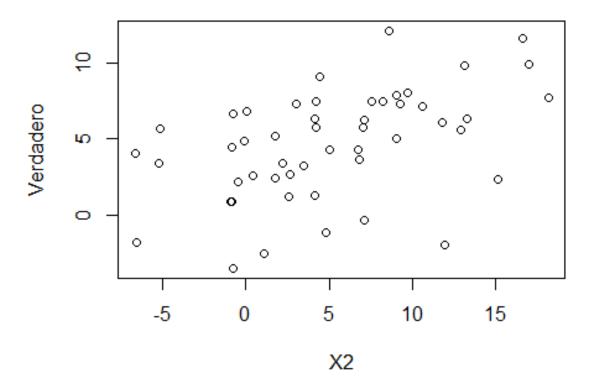
Si graficamos: $X_1 = T + e_1$



- I. XI yT ya no forman una línea recta
- 2. El error mueve los puntos en torno a la recta "latente" (o sea T)
- 3. Pero al ser el pequeño, los movimientos no son tan bruscos
- 4. La posición relativa de la persona/país/hogar con mayor score se mantiene



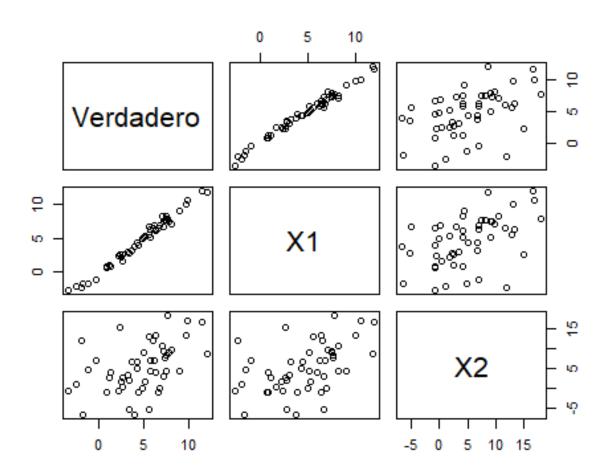
Error de medición



- I. X2 yT no parecen moverse igual
- 2. El error mueve mucho los puntos en torno a la recta "latente" (o sea T)
- 3. Pero al ser e2 grande, los movimientos son bruscos
- 4. La posición relativa de la persona/país/hogar con mayor score NO se mantiene



¿Qué diría Spearman de lo siguiente?



Persona, hogar, estado, país	Score verdadero	ΧI	X2
I	-4.4	-4.2	-3.5
2	-10.8	-11.2	-12
3	1.1	0.8	-0.3
4	2.1	2.3	-2.1
5	-6.6	-6.6	-3
6			



Atenuación de coeficientes de correlación

Cuadro 1.5. Preguntas de acceso a la alimentación en los hogares, ENIGH 2008

Acceso a la alimentación en los hogares Si en el hogar no hay personas menores de 18 años pase a la sección V. Equipamiento del hogar 1. En los últimos tres meses, por falta de dinero o recursos ¿alguna vez usted o algún adulto en su hogar tuvo una alimentación basada 7. En los últimos tres meses, por falta de dinero o recursos ¿alguna en muy poca variedad de alimentos? vez algún menor de 18 años en su hogar tuvo una alimentación basada en muy poca variedad de alimentos? Sí..... 111 Sí..... |1| 2. En los últimos tres meses, por falta de dinero o recursos ¿alguna vez usted o algún adulto en su hogar dejó de desayunar, comer o 8. En los últimos tres meses, por falta de dinero o recursos ¿alguna vez algún menor de 18 años en su hogar comió menos de lo que debía? Sí......|1| Sí......|1| No......[2] 3. En los últimos tres meses, por falta de dinero o recursos ¿alguna vez usted o algún adulto en su hogar comió menos de lo que usted 9. En los últimos tres meses, por falta de dinero o recursos ¿alguna piensa debía comer vez tuvieron que disminuir la cantidad servida en la comida a algún Sí..... 111 menor de 18 años del hogar? 4. En los últimos tres meses, por falta de dinero o recursos ¿alguna vez se quedaron sin comida? 10. En los últimos tres meses, por falta de dinero o recursos ¿alguna Sí..... |1| vez algún menor de 18 años sintió hambre pero no comió? No.....|2| Sí.....|1| No.......[2] 5. En los últimos tres meses, por falta de dinero o recursos ¿alguna vez usted o algún adulto de este hogar sintió hambre pero no comió? 11. En los últimos tres meses, por falta de dinero o recursos ¿algún menor de 18 años se acostó con hambre? Sí..... |1| No......[2] 6. En los últimos tres meses, por falta de dinero o recursos ¿alguna vez usted o algún adulto en su hogar sólo comió una vez al día o dejó 12. En los últimos tres meses, por falta de dinero o recursos ¿alguna de comer todo un día? vez algún menor de 18 años comió una vez al día o dejó de comer Sí.....|1| todo un día?

Como en un examen, lo que esperamos es que las respuestas sean un reflejo de inseguridad alimentaria.



Chance Spearman

Si las respuestas (1, 0) no reflejan el fenómeno, entonces los resultados serán aleatorios.

Si son aleatorios, la correlación se atenúa por el "ruido" en la medición



De nuevo

Mismo nivel latente



 \equiv

Persona B





Ítems

Score observado A

 \approx

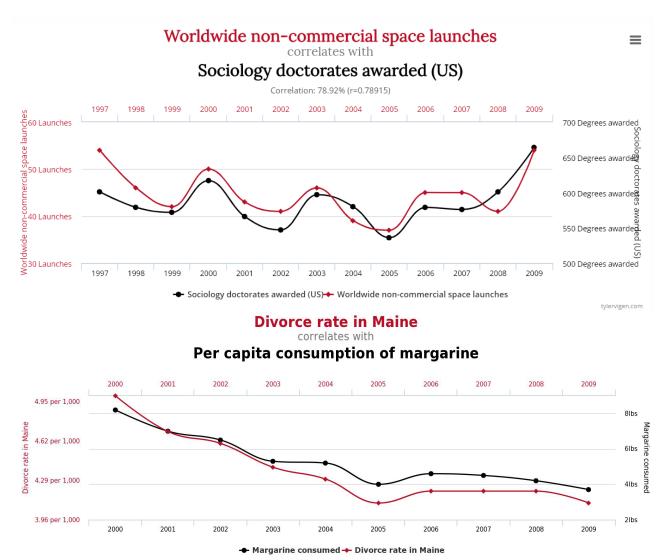
Score observado

Atenuación por error aleatorio





Componentes del modelo



¿Cómo saber que dos correlaciones rastrean la misma señal?

Sin modelo NO hay medición



Error de medición y confiabilidad

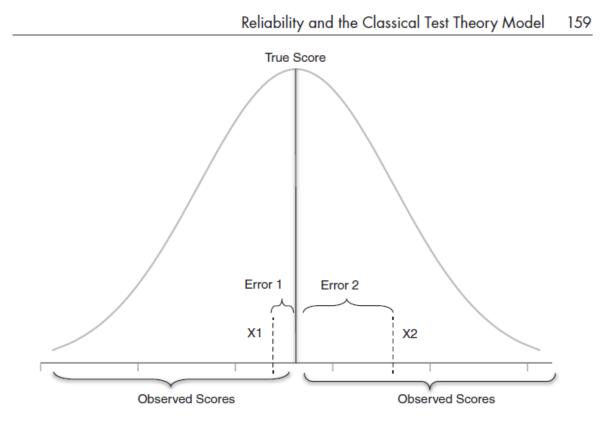


FIGURE 7.1. The distribution of observed scores around the true score.

Como decrece la confiabilidad de nuestras medidas/scores y la suerte se vuelve más importante, las magnitudes de los coeficientes de correlación se acercan a cero (las correlaciones positivas se vuelven menos positivas y las correlaciones negativas se vuelven menos negativas)

$$R_{XY} = \frac{r_{XY}}{\sqrt{reliability_X reliability_Y}}$$

 $\cite{confiable} \approx aleatorio^{-1}$?

Confiabilidad (reliability)

• Implicaciones de un concepto relativo de confiabilidad para la lógica de la medición.

$$Confiabilidad = \frac{Variabilidad\ individual}{Variabilidad\ individual + Error\ de\ medici\'on} = \frac{\sigma_{\theta}^2}{\sigma_{\theta}^2 + \sigma_{\varepsilon}^2}$$

- El coeficiente de confiabilidad refleja el grado en que un instrumento (artefacto) de medición es capaz de diferenciar entre individuos/objetos de estudio/unidades de observación (sujetos/hogares/familias/familias/escuelas/municipios/países/estados de la naturaleza).
- La confiabilidad de una medida está intimamente ligada a la población sobre la cual se quiere aplicar la medición.
 - No existe tal cosa como la confiabilidad de un instrumento/artefacto (a secas); el coeficiente sólo tiene significado cuando es aplicado a poblaciones específicas.
 - Es más difícil distinguir entre estados de la naturaleza (personas/hogares/municipios) si éstos son relativamente homogéneos que si éstos son muy diferentes.



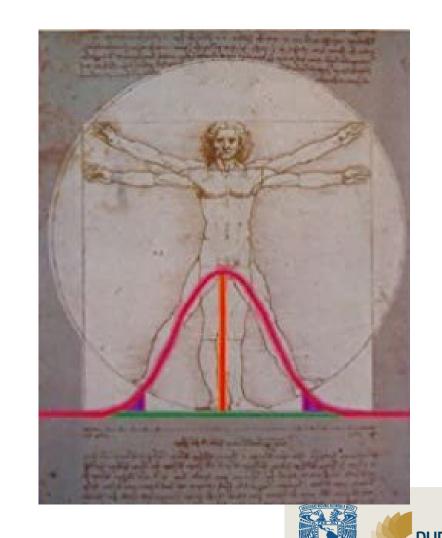
Confiabilidad (reliability)

- Confiabilidad es un término relativo (¿confiable para qué?)
 - Nuestra comodidad con un determinado error de medición depende de que éste sea una fracción pequeña del rango en las observaciones
 - Para proveer información útil acerca de un error de medición, siempre debe contrastarse con la variación esperada entre las observaciones a llevar a cabo.
 - Una función del cociente entre la señal y el ruido.
 - La proporción entre lo relevante y lo irrelevante de nuestras observaciones empíricas (puntajes observados o medidas).
 - La fracción de nuestras mediciones que **no** es irrelevante.
 - La razón entre la varianza de nuestro interés y la varianza total de nuestras mediciones.
 - El porcentaje de la variación de nuestras mediciones que no es error.
 - La proporción de la varianza de nuestras mediciones que se debe a diferencias entre los individuos/objetos de estudio ("el-mundo-allá-afuera").



Confiabilidad (reliability)

- No tiene sentido hablar de la confiabilidad (a secas) de un termómetro sin saber el rango de las temperaturas para las que va a ser utilizado.
- ES UN ERROR HABLAR DE LA CONFIABILIDAD DE UN TEST (ARTEFACTO).
 - La confiabilidad NO es una propiedad inherente e inmutable de una escala.
 - la confiabilidad se refiere al RESULTADO obtenido con un instrumento (artefacto) y no al instrumento (artefacto) mismo.
 - La confiabilidad ES el resultado de la interacción entre el instrumento/artefacto y el sistema empírico al que éste es aplicado (objetos/individuos y su situación).

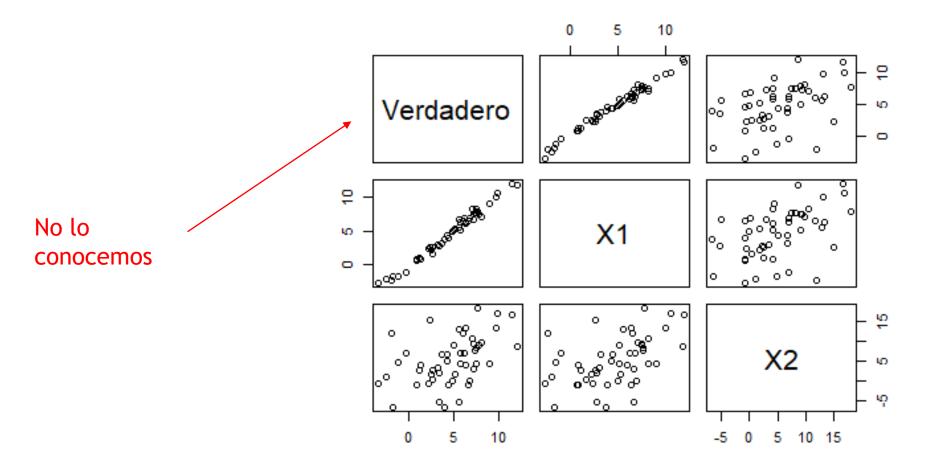


¿Cómo se estima la confiabilidad?

Teoría clásica del test



Scores verdaderos



Usar la información que tenemos para poder estimar el error



La gran dificultad

Esto está muy bien porque conocemos el valor del score verdadero.

Pero nunca lo conocemos

Sólo tenemos X1 y X2.

¿Cómo sabemos cuál tiene menos ruido respecto al valor verdadero?



Información y supuestos de la TCT

	Matriz de c	orrelació	า	
	Verdadero	X1	X2	
Verdadero		1	0.9	0.4
X1	0.	9	1	0.4
X2	0.	4	0.4	1

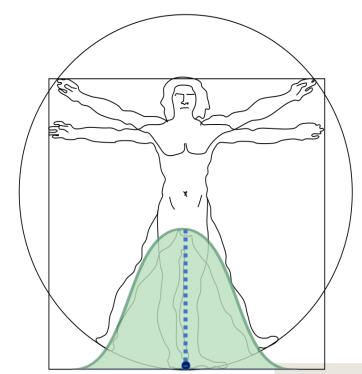
El cálculo de confiabilidad en la TCT gira en torno a los supuestos que nos permiten utilizar los valores de X1 y X2 (*Test paralelos*, equivalencia tau, ..., half-Split reliability)



¿Cómo estimar confiabilidad?

$$Confiabilidad = \frac{Variabilidad\ individual}{Variabilidad\ individual + Error\ de\ medición} = \frac{\sigma_s^2}{\sigma_s^2 + \sigma_e^2}$$

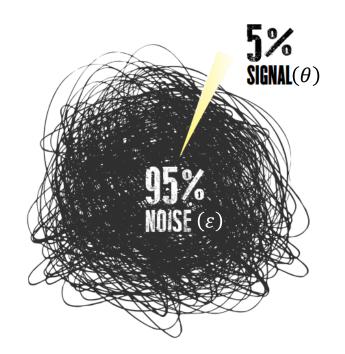
Desafortunadamente, todo lo discutido hasta ahora no sirve de nada si no podemos estimar σ_s^2 y σ_e^2

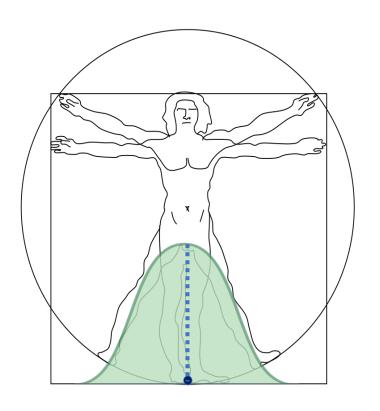




¿Cómo estimar confiabilidad?

• ¿Es posible deducir la composición de señal y ruido a partir de UNA observación (por objeto de estudio)?







Modelos (estadísticos) a partir de la TCT

- Test paralelos: Primera mitad del Siglo XX
- Equivalencia Tau: Mitad del Siglo XX
- Medidas congéneres: Finales del XX

• Ecuaciones estructurales y variables latentes: Presente



Pensemos estos supuestos

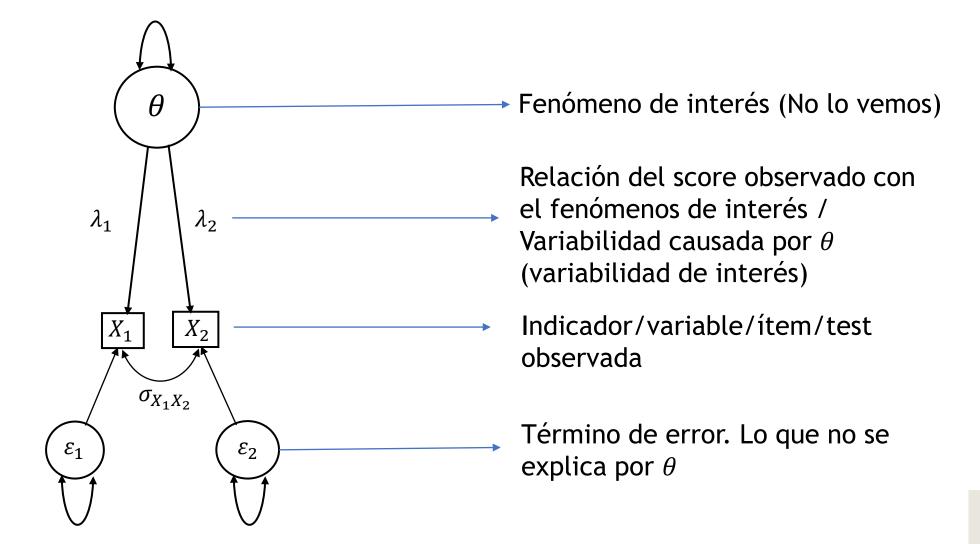
	Cuadro C.1. Por	entaje de no	especificad	los por ent	idad federa	tiva según i	indicador so	cioeconón	nico, 2015	
Clave de la entidad federativa	Entidad federativa	% Población de 15 años o más analfabeta	% Población de 15 años o más sin primaria completa	% Ocupantes en viviendas sin drenaje ni sanitario	% Ocupantes en viviendas sin energía eléctrica	% Ocupantes en viviendas sin agua entubada	% Viviendas con algún nivel de hacinamiento	% Ocupantes en viviendas con piso de tierra	% Población en localidades con menos de 5 000 habitantes	% Población ocupada con ingreso de hasta 2 salarios mínimos
	Nacional	0.90	0.41	0.36	0.24	0.30	0.31	0.57	_	9.69
01	Aguascalientes	0.38	0.12	0.04	0.03	0.05	0.05	0.09	_	7.28
02	Baja California	0.47	0.26	0.07	0.02	0.05	0.06	0.16	_	10.89
03	Baja California Sur	0.72	0.28	0.22	0.14	0.17	0.17	0.54	_	10.06
04	Campeche	0.47	0.14	0.04	0.03	0.02	0.07	0.18	_	6.83
05	Coahuila de Zaragoza	0.93	0.44	0.22	0.05	0.14	0.11	0.32	_	9.01
06	Colima	0.54	0.12	0.09	0.05	0.07	0.06	0.26	_	6.85
07	Chiapas	0.96	0.19	0.18	0.13	0.11	0.22	0.36	_	9.85
08	Chihuahua	2.41	2.08	2.02	1.90	1.93	1.97	2.07	_	9.74

Partimos de que son tests del mismos fenómeno... ¿Estas 8 variables se relacionarán de igual manera con la marginación? ¿Tendrán la misma varianza?

¿Si ninguna de esas condiciones se cumple, puedo estimar el error?



Lenguaje SEM: Variables latentes





Paralelas, tau-equivalent and congeneric

• Si los indicadores son reflejo del mismo fenómeno, estos pueden clasificarse de acuerdo a su grado de similaridad:

BOX 7.1 Properties of Parallel, Tau-Equivalent, Essentially Tau-Equivalent, and Congeneric Measures							
Type of							Relationship between
measure	μ_{X}	σ_{x}^{2}	σ_{\uparrow}^2	$\sigma_{\scriptscriptstyle E}^2$	$\sigma_{\chi_1 \chi_2}$	$ ho_{X_1X_2}$	true scores
Parallel	Must be equal	Must be equal	Must be equal	Must be equal	Must be equal	Must be equal	$t_i = O + 1 * t_j$
Tau-equivalent	Must be equal	May be equal or unequal	Must be equal	May be equal or unequal	Must be equal	May be equalor unequal	$t_i = O + 1 * t_j$
Essentially tau-equivalent	May be equal or unequal	May be equal or unequal	Must be equal	May be equal or unequal	Must be equal	May be equal or unequal	$t_i = a_{ij} + 1 * t_j$
Congeneric	May be equal or unequal	May be equal or unequal	May be equal or unequal	May be equal or unequal	May be equal or unequal	May be equal or unequal	$t_i = a_{ij} + b_{ij} * t_j$

En los tres primeros casos la relación con la variable latente (t) es igual

Es factible estimar la confiabilidiad como vimos (una de las x juega el papel de t). (Bandalos p. 167)

Noten que las condiciones van de más estrictas a menos estrictas



¿Cómo podemos saber que esto esta pasando?

Supuestos:

- Test paralelos: Primera mitad del Siglo XX
- Equivalencia Tau: Mitad del Siglo XX
- Medidas congéneres: Finales del XX
- Ecuaciones estructurales y variables latentes: Presente



BOX 7.1 Properties of Parallel, Tau-Equivalent, Essentially Tau-Equivalent, and Congeneric Measures Relationship between Type of true scores measure μ_{X} σ_1^2 $\sigma_{\chi_1\chi_2}$ $\rho_{X_1X_2}$ Parallel Must be Must be Must be Must be Must be Must be $t_i = 0 + 1 * t_i$ equal equal equal equal equal equal May be May be Must be Tau-equivalent Must be Must be May be $t_i = 0 + 1 * t_i$ equal or equal equal equal or equal equalor unequal unequal unequal May be Essentially May be Must be May be Must be May be $t_i = a_{ii} + 1 * t_i$ equal or ta u-eq uivale nt equal or equal equal or equalor equal unequal unequal unequal unequal Congeneric May be May be May be May be May be May be $t_i = a_{ii} + b_{ii} * t_i$ equal or equal or equal or equal or equal or equal or unequal unequal unequal unequal unequal unequal

 $Y_1=0+1*Y_2$

La medias son iguales

Las varianzas tambien





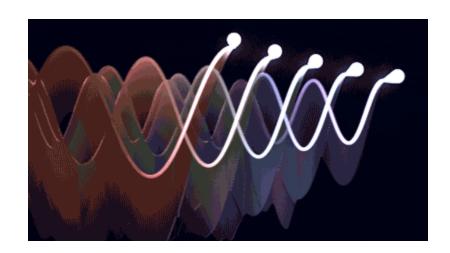
Sistema bajo medición

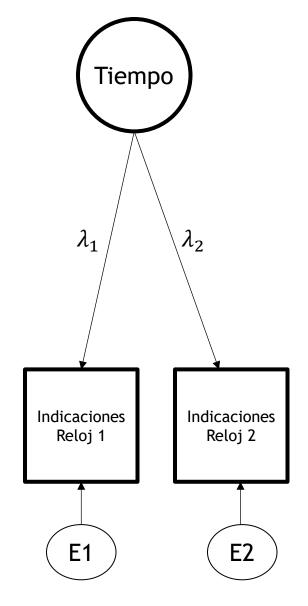


Indicaciones instrumentales



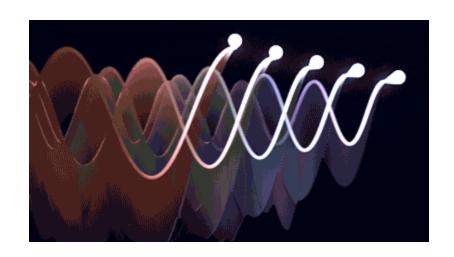


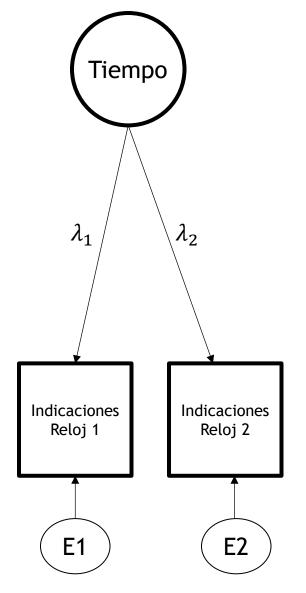








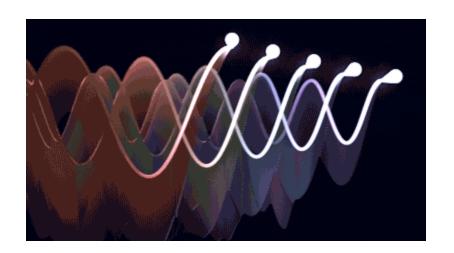


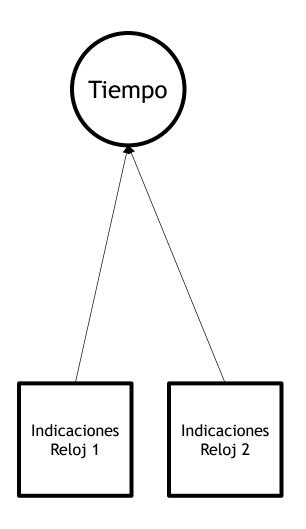








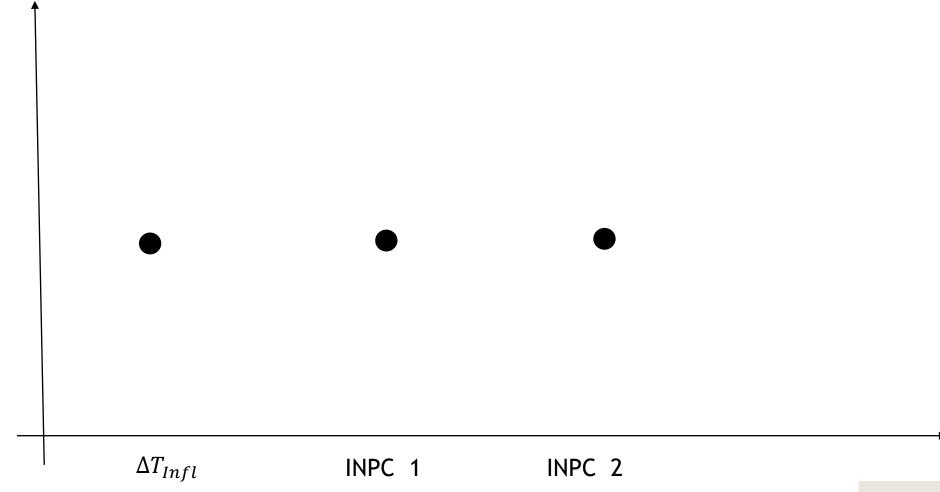





 $\lambda_1 \neq \lambda_2$

¿Qué significaría un modelo de este tipo (formativo)?

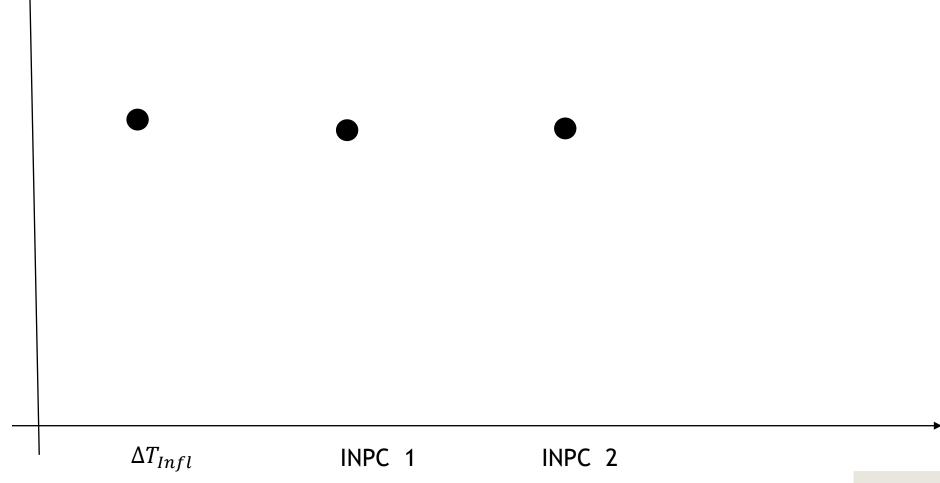




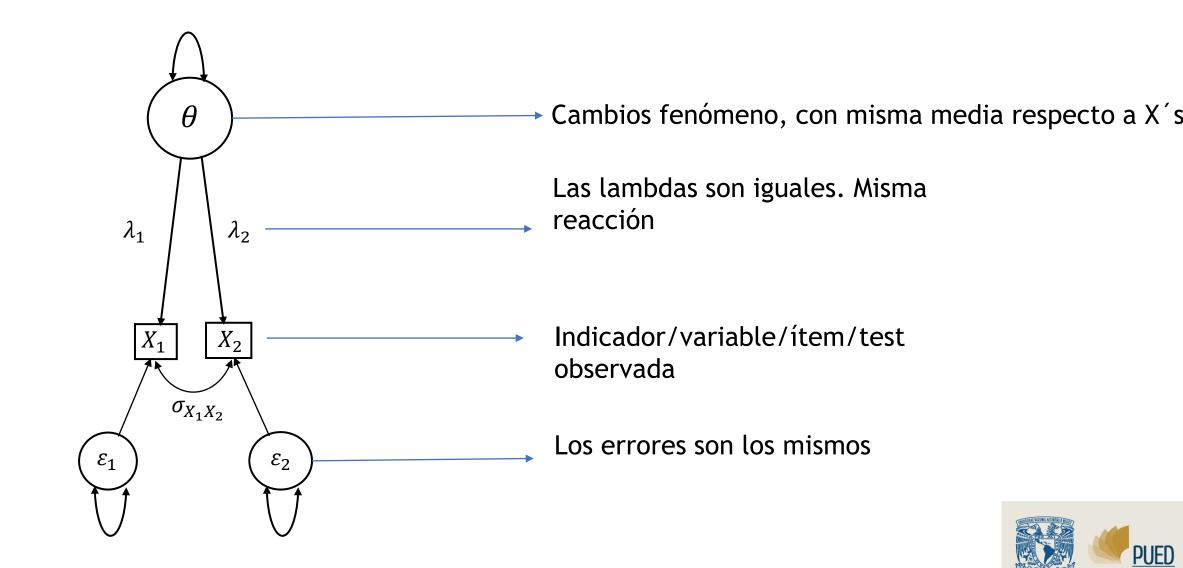












Tests (medidas/indicadores) paralelos

No siempre puedo repetir y además en medición derivada busco ampliar el espectro de información

Incluyo más ítems y supongo que son paralelos

```
load("Data")
head(D)
```

```
## X1 X2 X3 X4

## 1 0.1079993 0.1263256 0.1835274 0.1068131

## 2 -2.1913068 -2.4435596 -2.0918066 -2.3461443

## 3 -0.7024488 -0.6761810 -0.8373665 -0.5846087

## 4 -0.4593898 -0.6938371 -0.3483979 -0.2026447


## 5 0.6445464 0.5939276 0.9114592 0.4786136

## 6 -0.9880279 -0.8805711 -0.9995512 -1.1631823
```



Tests (medidas/indicadores) paralelos

```
## X1 X2 X3 X4
## X1 1.0000000 0.9836211 0.9837738 0.9834104
## X2 0.9836211 1.0000000 0.9676541 0.9673263
## X3 0.9837738 0.9676541 1.0000000 0.9670745
## X4 0.9834104 0.9673263 0.9670745 1.0000000
```





¿Cómo podemos saber que esto esta pasando?

Supuestos:

- Test paralelos: Primera mitad del Siglo XX
- Equivalencia Tau: Mitad del Siglo XX
- Medidas congéneres: Finales del XX
- Ecuaciones estructurales y variables latentes: Presente



BOX 7.1
Properties of Parallel, Tau-Equivalent, Essentially Tau-Equivalent, and Congeneric Measures

Type of measure	μ_{X}	$\sigma_{\rm x}^2$	σ_1^2	$\sigma_{\it E}^2$	$\sigma_{_{oldsymbol{\chi}_1oldsymbol{\chi}_2}}$	$\rho_{X_1X_2}$	Relationship between true scores
Parallel	Must be equal	Must be equal	$t_i = O + 1 * t_j$				
Tau-equivalent	Must be equal	May be equal or unequal	Must be equal	May be equal or unequal	Must be equal	May be equal or unequal	$t_i = O + 1 * t_j$
Essentially tau-equivalent	May be equal or unequal	May be equal or unequal	Must be equal	May be equal or unequal	Must be equal	May be equal or unequal	$t_i = a_{ij} + 1 \star t_j$
Congeneric	May be equal or unequal	May be equal or unequal	$t_i = a_{ij} + b_{ij} * t_j$				

$$Y_1 = a + 1 * Y_2$$

La medias no tienen que ser iguales



